

隐式模型中的语义插值

Yannic Kilcher, Aurélien Lucchi, Thomas Hofmann

Department of Computer Science

ETH Zurich

{yannic.kilcher,aurelien.lucchi,thomas.hofmann}@inf.ethz.ch

ABSTRACT

在隐式模型中，通常会在潜在空间的采样点之间进行插值。正如本文所示，必须谨慎处理编码向量的分布假设与插值路径几何结构之间的匹配问题。否则，关于中间点质量和语义的典型假设可能缺乏依据。基于我们的分析，我们建议修改先验编码分布，使更多的概率质量集中在原点附近。结果，线性插值路径不仅是最短路径，而且无论潜在空间的维度如何，都能保证经过高密度区域。在标准基准图像数据集上的实验表明，生成样本的质量有明显的视觉提升，并且插值路径也更具语义意义。

1 引言

连续潜变量模型在统计学中已发展和研究了近一个世纪，因子分析 (Young (1941); Bartholomew (1987)) 是最具代表性且应用最广泛的一类模型。在神经网络领域，自编码器被用于寻找低维编码并实现低重构误差 (Baldi & Hornik (1989); DeMers & Cottrell (1993))。近年来，人们对隐式模型的兴趣日益增加，这类模型通过随机源驱动复杂的生成机制 (参见 MacKay (1995))。这包括广为人知的变分自编码器 (VAEs, Kingma & Welling (2013); Rezende et al. (2014)) 以及生成对抗网络 (GANs, Goodfellow et al. (2014))。通常，人们定义一个确定性机制或生成器 $G_\phi: \mathbb{R}^d \rightarrow \mathbb{R}^m$, $\mathbf{z} \mapsto G_\phi(\mathbf{z}) = \mathbf{x}$, 其由 ϕ 参数化，通常以深度神经网络 (DNN) 实现。该映射随后与代码分布 $\mathbf{z} \sim \mathcal{P}_\mathbf{z}$ 结合，从而诱导出分布 $\mathbf{x} \sim \mathcal{P}_\mathbf{x}$ 。已知在适度的正则性条件下，通过适当选择生成器，任意 $\mathcal{P}_\mathbf{x}$ 均可从任意固定的 $\mathcal{P}_\mathbf{z}$ 获得 (参见 Kallenberg (2006))。基于 DNN 的表示能力和灵活性，这一观点促使人们认为代码分布应尽可能简单，例如最常见的 $\mathcal{P}_\mathbf{z} = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。隐式模型本质上是采样装置，可在无需显式访问其所定义密度的情况下进行训练和使用。它们在生成在感知上与自然生成样本难以区分的样本方面展现出巨大潜力 (Radford et al. (2015))，目前正受到广泛研究。

早期关于嵌入模型的工作，例如 Mikolov et al. (2013a) 的词嵌入，已经表明语义关系和类比可以通过嵌入的仿射结构自然捕捉 (Mikolov et al. (2013c); Levy & Goldberg (2014))。这启发了在生成对抗网络 (GANs) 等隐式模型中使用仿射向量运算和线性插值，结果显示在图像空间中能够实现语义插值 (参见 Radford et al. (2015); White (2016))。这些遍历实验也被用来证明深度生成模型不仅记忆了训练数据，还学习到了能够泛化到未见数据的模型。

然而，如 White (2016) 所指出的，常用的线性插值存在一个主要缺陷，即忽略了潜在空间的流形结构。事实上，沿着直线遍历潜在空间可能会进入低密度区域，在这些区域——根据定义——生成器并未经过充分训练。这一点很容易理解，因为对于 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，我们得到

$$\|\mathbf{z}\|^2 \sim \chi^2(d), \quad \text{and hence} \quad \mathbf{E}\|\mathbf{z}\|^2 = d, \quad \text{Var} \left[\frac{\|\mathbf{z}\|^2}{d} \right] = \frac{2}{d}. \quad (1)$$




图 1: 示意图展示了正态先验分布的质量分布情况。在高维度下, 大部分质量集中在蓝色所示的外层壳区, 而红色所示的中间区域几乎无质量。在线性插值两点之间时, 会产生绿色虚线轨迹, 从而经过空间中概率质量较低的区域。相比之下, 沿着蓝色的大圆弧路径采样更有可能产生有效样本, 但这些路径也可能不稳定, 因为其方差较高 (详见正文)。

相对于平均值, 平方码向量范数的方差随潜在空间维度按 $\mathcal{O}(\frac{1}{d})$ 衰减。因此当 d 增大时, 概率质量会集中在半径为 $\sqrt{d}$ 的 $(d-1)$ -球面附近的薄壳内。如图 1 所示, 该球面上任意两点之间的插值路径始终经过内部, 且它们之间的距离越大, 路径中点就越接近原点。

尽管我们并非首个指出这一弱点的团队, 但迄今为止尚无严谨的研究来分析该现象, 并提出显著改进的插值方案。White (2016) 提出使用球面线性插值。然而需要注意的是, 这种方案生成的插值曲线与大圆弧非常相似。这些路径可能不稳定 (例如, 考虑对超球面相对极点上的点进行轻微扰动), 而且路径过长, 会经过与两端点图像几乎毫无共同之处的编码。

为此目标, 我们作出以下贡献:

- i) 我们通过表征潜在在编码先验与插值中间点所诱导的有效分布之间的 KL 散度, 对这一现象进行了恰当分析。
- ii) 我们提出了一种改进的先验分布, 该分布能有效将更多概率质量集中在原点附近, 并且可证明地以与维度无关的方式控制 KL 散度。
- iii) 我们认为, 在这个新模型中, 通过直线进行的线性插值不会出现原模型中存在的问题。
- iv) 我们进行了大量实验, 展示了插值路径的不同特性, 并清晰地证明了图像中间样本的视觉质量得到了提升。

2 方法

2.1 从正态分布中进行朴素采样

分布不匹配 我们考虑常见的生成对抗网络 (GAN) 框架, 其中生成器为 G , 潜在代码向量从各向同性正态分布中采样, 即 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ 。在典型的遍历实验中, 人们会独立采样两个代码向量 $\mathbf{z}_0, \mathbf{z}_1 \in \mathbb{R}^d$, 并通过一条直线 $h: [0; 1] \rightarrow \mathbb{R}^d$, $t \mapsto h(t) = (1-t)\mathbf{z}_0 + t\mathbf{z}_1$ 在它们之间进行插值。在此过程中, 人们期望, 例如, 中点 $\mathbf{z}' = h(\frac{1}{2})$ 应对应于一个在语义上同时与 $G(\mathbf{z}_0)$ 和 $G(\mathbf{z}_1)$ 相关的样本。

然而, 根据前述论点, 在实践中常常发现代码 $h(\frac{1}{2})$ 落在潜在空间中概率质量较低的区域。因此, 生成的样本通常不能代表数据分布。为进一步阐明这一点, 请注意, 中点平方范数的分布可以被证明服从 Gamma 分布, 即

$$\|\mathbf{z}'\|^2 = \left\| \frac{\mathbf{z}_0 + \mathbf{z}_1}{2} \right\|^2 = \frac{2\sigma^2}{4} \|\mathbf{n}\|^2 \quad \text{where } \mathbf{n} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (2)$$

因此,

$$\|\mathbf{z}'\|^2 \sim \frac{\sigma^2}{2} \chi^2(d) = \Gamma\left(\frac{d}{2}, \sigma^2\right) \quad (3)$$

特别地, 这表明在期望意义下, 中点的范数比端点的范数小一个因子 $\frac{1}{\sqrt{2}}$ 。从这一观察中我们可以得出什么结论? 主要结论是: 用于训练生成器网络的过程与在潜在空间遍历时所采用的评估策略不一致。事实上, 在训练时, 生成器网络是使用其平方范数服从 $\sigma^2 \chi^2(d)$ 分布的向量进行训练的。然而在测试时, 遍历过程经过的中点其平方范数则服从 $\frac{\sigma^2}{2} \chi^2(d)$ 分布。显然, 这导致了严重的训练-测试不匹配问题。

形式分析 在我们正式化至今所作的观察之前, 让我们先收集一些后续分析中需要用到的 χ^2 分布的性质。在统计学中, χ^2 分布通常通过公式 (1) 引入。其密度函数的定义域为非负实数, 并可证明其表达式为

$$f_{\chi^2}(u; d) = \frac{1}{2^{\frac{d}{2}} \Gamma(\frac{d}{2})} u^{\frac{d}{2}-1} e^{-\frac{u}{2}}, \quad \text{for } u \geq 0 \quad (4)$$

$\sigma^2 \chi^2(d)$ 分布是具有形状参数 $\frac{d}{2}$ 和尺度 $2\sigma^2$ 的 $\Gamma(\frac{d}{2}, 2\sigma^2)$ Gamma 分布的一个特例。这一推广非常有用, 因为我们现在也可以将中点分布识别为一种 Gamma 分布, 即 $\Gamma(\frac{d}{2}, \sigma^2)$ 。以下引理给出了这两个潜在空间分布之间 KL 散度的特征描述。

Lemma 1. 令 $\mathbf{z} \sim \Gamma(\frac{d}{2}, 2\sigma^2)$ 和 $\mathbf{z}' \sim \Gamma(\frac{d}{2}, \sigma^2)$ 对任意 $\sigma > 0$, 则

$$KL(\mathbf{z} \parallel \mathbf{z}') = \frac{d}{2} (1 - \log 2) \quad (5)$$

证明. 使用简单的微积分。 □

综上所述, $KL(\mathbf{z} \parallel \mathbf{z}')$ 随 d 严格增加, 在给定速率下随 d 线性增长。然而, 正如 Arjovsky & Bottou (2017) 所指出的, 我们需要一个足够高的潜在空间维度, 至少要匹配数据流形的内在维度。否则, $\mathcal{P}_{\mathbf{z}}$ 不可能保持连续, 从而可能导致生成对抗网络中常见的稳定性问题。因此, 似乎难以避免随着 d 增大而带来的 KL 散度发散。

球面插值 一种应对上述问题的解决方案是使用球面插值，本质上是对超球面上测地线概念的推广。我们已经提及了White (2016) 提出的方案，该方案采用 $\theta := \angle(\mathbf{z}_0, \mathbf{z}_1)$ 进行插值，

$$h(t) = \frac{\sin((1-t)\theta)}{\sin(\theta)} \mathbf{z}_0 + \frac{\sin(t\theta)}{\sin(\theta)} \mathbf{z}_1, \quad \mathbf{z}' = h(\tfrac{1}{2}) = \frac{\sin(\frac{\theta}{2})}{\sin(\theta)} (\mathbf{z}_0 + \mathbf{z}_1) = \frac{1}{\cos(\frac{\theta}{2})} \frac{\mathbf{z}_0 + \mathbf{z}_1}{2}. \quad (6)$$

很容易验证，若 $\|\mathbf{z}_0\| = \|\mathbf{z}_1\| = r$ ，则该曲线遵循连接 $\mathbf{z}_0$ 与 $\mathbf{z}_1$ 的半径为 r 的大圆。在更一般的情况下，只要 $|\theta| \leq \pi/2$ ，我们就能得到界限 $\min\{\|\mathbf{z}_0\|, \|\mathbf{z}_1\|\} \leq \|h(t)\| \leq \max\{\|\mathbf{z}_0\|, \|\mathbf{z}_1\|\}$ 。尽管这种插值公式在动画旋转的原始语境中（如 Shoemake (1985) 所示）可能适用，但众所周知，对于较大的角度，它无法为生成对抗网络（GANs）生成语义上合理的插值路径，因为这些路径往往过长，常常经过看似无关的图像。此外，球面插值破坏了在其他上下文中已被证明非常有用的简单仿射向量运算，并且这种运算已被证实能够将非线性变差因素解耦为简单的线性统计量（Mikolov et al. (2013a)）。因此，我们的目标是通过一种方式修复发散问题，从而能够在代码空间中保持线性插值。

2.2 伽马距离模型

除了在缺乏其他要求时具有某种非信息性之外，各向同性的正态分布作为编码向量分布并无特殊之处。此处我们建议保持潜在空间分布的各向同性，但改变范数或距原点距离的分布。因此，我们将分布分解如下：

$$\mathbf{v} \sim \text{Uniform}(\mathcal{S}^{d-1}), \quad r \sim \mathcal{P}_r, \quad \mathbf{z} = \sqrt{r} \mathbf{v}. \quad (7)$$

选择 $\mathcal{P}_r = \chi^2(d)$ 使我们回到普通情形及其带来的问题。相反，我们消除了 $\mathcal{P}_r$ 选择中的维度依赖性。一种简单的方法是保持在具有固定形状的 Γ -分布族内，并设定

$$\mathcal{P}_r = \Gamma(\tfrac{1}{2}, \theta), \quad \theta > 0. \quad (8)$$

特别地，如果 $\theta = 2$ ，这将导致与 1 维高斯情形下相同的边缘分布关于范数，从而抵消半径为 $\sqrt{d}$ 的超球面上的集中效应。

Proposition 1. 使用式 (7)-(8) 中描述的模型，我们有

$$\|\mathbf{z}_0\|^2, \|\mathbf{z}_1\|^2 \sim \Gamma(\tfrac{1}{2}, \theta), \quad \left\| \frac{\mathbf{z}_0 + \mathbf{z}_1}{2} \right\|^2 \sim \Gamma(\tfrac{1}{2}, \tfrac{1}{2}\theta). \quad (9)$$

此外， $\mathbf{z}$ 与中点 $\mathbf{z}'$ 之间的 KL 散度为

$$KL(\mathbf{z} \parallel \mathbf{z}') = \frac{1}{2}(1 - \log 2) \approx 0.35. \quad (10)$$

我们获得了什么？我们想提出两点观察：(i) 公式 (10) 表明， KL 散度是常数，且不会随潜在空间维度的增加而发散。(ii) 尽管保持散度恒定，伽马采样过程仍可通过自由尺度参数 θ 调节噪声水平（类似于原始采样过程中的 σ ）。

3 实验

实验结果。 本文所述实验所采用的设置密切遵循生成对抗网络（GAN）研究中的常见配置，具体细节见附录。

3.1 来自 GAN 的样本，带有 Γ -先验


图 3.1 比较了从正态先验和伽马先验生成的样本在不同基准图像数据集上的表现。除了直接替换噪声采样外，我们未使用任何额外技巧来获得这些结果。这表明使用伽马先验的 GAN 可以像传统 GAN 一样轻松训练。



(a) Samples from CelebA with normal (left) and gamma (right) prior



(b) Samples from LSUN kitchen with normal (left) and gamma (right) prior




(c) Samples from LSUN bedroom with normal (left) and gamma (right) prior.



(d) Samples from MNIST with normal (left) and gamma (right) prior.



(e) Samples from SVHN with normal (left) and gamma (right) prior.



(f) Samples from CIFAR10 with normal (left) and gamma (right) prior.

3.2 遍历实验

此处我们从球体中心两侧相同长度的一对点出发，执行两种不同的遍历方式。一种遍历在欧几里得意义上直线穿过球体中心，另一种则沿着球面上的测地线进行。

我们对比了使用多元正态先验训练的模型与使用我们建议的伽马先验的模型的两种遍历路径。除了展示采样得到的遍历轨迹外，我们还展示了这些轨迹上判别器活性值的平均结果，该结果基于 1000 个轨迹样本的平均值。图中显示的是判别器活性值的均值及其一个标准差。更多遍历样本可在附录中找到。

3.2.1 球面测地线遍历

图 2 和 3 展示了在潜在空间球面上沿大圆的遍历过程以及判别器的活性值。请注意，路径通常会经过真实且有趣的样本，但并不在语义上对给定的两个端点进行插值。此外，请注意判别器的活性值在路径上保持不变，这意味着它认为所有样本具有相同的可能性。




图 2: 在 CelebA 上使用多元正态先验进行球面测地线遍历。




图 3: 在 CelebA 上使用伽马先验的球面测地线遍历。

3.2.2 直线欧几里得遍历

图 4 和 5 展示了在两个端点之间的直线路径上的遍历过程以及判别器的活性值。对于常规先验，这会导致无意义的结果，因为我们经过了生成对抗网络在训练期间从未见过的潜在空间。这一缺陷的另一个迹象是，判别器活性值在遍历中点附近急剧下降。

对于伽马先验，然而，直线遍历在端点之间产生了平滑的插值。需要注意的是，这些遍历具有更强的语义性，路径上的样本确实位于端点的“中间”。还请注意，在中点处出现了均值样本。在人脸的情况下，这些中点（即最接近原点的点）往往表现为非常常见的面孔，正视图且具有很少的不寻常特征。在附录中的 LSUN 数据集遍历中，这种现象更加明显。




图 4: 在 CelebA 上使用多元正态先验进行直接欧几里得遍历。



图 5: 在 CelebA 上使用伽马先验的直角欧几里得遍历。

3.3 潜在均值样本

由于我们在使用伽马先验的遍历实验中注意到一个有趣的现象：采样得到的端点对的中点趋向于收敛到可称为 均值样本的位置，因此我们利用训练好的模型，特意在坐标原点附近进行采样，以直接获得这些均值样本。图 6 展示了我们不同数据集的均值样本。




图 6: 在使用伽马先验训练的生成对抗网络中，潜在空间原点附近的样本。

3.4 潜在空间维度的影响

我们在此通过实验验证了关于潜在空间维度对潜在空间遍历影响的理论预测的有效性。我们为多种潜在空间维度训练了生成对抗网络，并使用获得的生成器进行了直线潜在遍历。图 7 展示了在 CelebA 数据集上取得的结果，我们观察到在低维度情况下，使用正态先验和伽马先验训练的生成器均取得了令人满意的效果。然而，随着维度的增加，使用正态先验训练的生成器性能迅速下降，而使用伽马先验训练的生成器则保持稳定。因此，这些结果与之前的理论预测一致。更多不同数据集上的结果见附录。




图 7: 在具有不同潜在空间维度的 CelebA 数据集上，使用正态先验（顶部）和伽马先验（底部）生成器进行直接遍历。

3.5 代数实验

既然我们已经确定使用伽马先验会使潜在空间的性质更接近欧几里得空间，那么我们可以进一步探讨这是否也有助于另一个常被用于评估生成式模型的任务。

我们进行了多种类比实验，例如 Mikolov et al. (2013b) 所描述的实验，该实验表明词向量表现出诸如“巴黎 - 法国 + 意大利 = 罗马”的关系。为了进行此类实验，我们使用了 CelebA 数据集，该数据集为每个样本提供了多个二值属性标签。考虑两个属性， $\mathcal{A}$ 和 $\mathcal{B}$ 。我们用 $[A, B]$ 表示同时具有这两个属性的样本对，用 $[a, b]$ 表示不具有这两个属性中的任何一个的样本，用 $[A, b], [a, B]$ 表示仅具有其中一个属性的样本。

对于每一对属性 $\mathcal{A}, \mathcal{B}$ ，我们希望

$$z([A, B]) - z([a, B]) + z([a, b]) \doteq z([A, b]) \quad (11)$$

其中， $z([\bullet, \bullet])$ 表示一组具有（或不具有）给定属性的样本的潜在表示的均值。

使用预训练模型，我们通过分类器判断样本所属类别，从每个类别中采样一个批量的样本来自生成器。然后，我们使用以下的潜在代数得分（LAS）来量化公式 11 中描述的类比成立的程度：

$$\text{LAS} = \frac{2}{N(N-1)} \sum_{\mathcal{A} \neq \mathcal{B}} \frac{\|z([A, B]) - z([a, B]) + z([a, b]) - z([A, b])\|_2^2}{m_{\|z\|_2^2}} \quad (12)$$

其中 N 为二元属性的数量， $m_{\|z\|_2^2}$ 为所有使用潜向量的均方范数。表 1 中的结果表明，伽马采样过程产生的类比效果优于使用正态先验的标准采样。

Prior	LAS
normal	0.007496
gamma	0.005638

表 1: CelebA 潜在代数得分（数值越低越好）

4 相关工作

学成的潜在表示通常允许向量空间运算转化为数据空间中的语义操作 Radford et al. (2015); Larsen et al. (2015)。早期的研究表明，GAN 的潜在空间在数据空间中找到了语义方向（例如对应于眼镜和微笑）Radford et al. (2015)。近期的工作还专注于学习更好的相似度度量 Larsen et al. (2015)，或对潜在空间进行更精细的语义分解 Donahue et al. (2017)。因此，当前 GAN 模型的评估通常通过采样一对点并在潜在空间中进行线性插值，或执行其他类型的噪声向量运算 Bojanowski et al. (2017) 来完成。这导致从概率质量极低的位置采样潜在空间。这一观察也出现在 White (2016) 中，其建议用球面线性插值替代线性插值，以防止偏离模型的先验分布。

5 结论

虽然生成对抗网络（GAN）标准的潜在向量采样方法基于在潜在空间上使用正态分布，但我们表明这种方法可能会产生在模型分布下不太可能的样本。我们讨论了该过程如何受到维数灾难的影响，并展示了如何通过一种简单的替代方法解决此问题。最后，我们提供了大量实验，明确展示了使用我们提出的伽马采样方法生成的样本在视觉效果上的显著提升。

参考文献

- Martin Arjovsky and Léon Bottou. Towards principled methods for training generative adversarial networks. In *NIPS 2016 Workshop on Adversarial Training*. In review for *ICLR*, volume 2016, 2017.
- Pierre Baldi and Kurt Hornik. Neural networks and principal component analysis: Learning from examples without local minima. *Neural networks*, 2(1):53–58, 1989.
- D. J. Bartholomew. *Latent Variable Models and Factor Analysis*. London: Griffin, 1987.
- Piotr Bojanowski, Armand Joulin, David Lopez-Paz, and Arthur Szlam. Optimizing the latent space of generative networks. *arXiv preprint arXiv:1707.05776*, 2017.
- David DeMers and GW Cottrell. n-linear dimensionality reduction. *Adv. Neural Inform. Process. Sys*, 5:580–587, 1993.
- Chris Donahue, Akshay Balsubramani, Julian McAuley, and Zachary C Lipton. Semantically decomposing the latent spaces of generative adversarial networks. *arXiv preprint arXiv:1705.07904*, 2017.
- Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative Adversarial Nets. pp. 2672–2680, 2014.
- Olav Kallenberg. *Foundations of modern probability*. Springer Science & Business Media, 2006.
- Diederik P Kingma and Max Welling. Auto-Encoding Variational Bayes. *arXiv.org*, December 2013.
- Anders Boesen Lindbo Larsen, Søren Kaae Sønderby, Hugo Larochelle, and Ole Winther. Autoencoding beyond pixels using a learned similarity metric. *arXiv preprint arXiv:1512.09300*, 2015.
- Omer Levy and Yoav Goldberg. Linguistic regularities in sparse and explicit word representations. In *Proceedings of the eighteenth conference on computational natural language learning*, pp. 171–180, 2014.
- David JC MacKay. Bayesian neural networks and density networks. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, 354(1):73–80, 1995.
- Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient Estimation of Word Representations in Vector Space. *arXiv.org*, January 2013a.
- Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013b.
- Tomas Mikolov, Wen-tau Yih, and Geoffrey Zweig. Linguistic regularities in continuous space word representations. In *hlt-Naacl*, volume 13, pp. 746–751, 2013c.

-
- Alec Radford, Luke Metz, and Soumith Chintala. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks. November 2015.
- D J Rezende, S Mohamed, and D Wierstra. Stochastic backpropagation and approximate inference in deep generative models. *arXiv.org*, 2014.
- Ken Shoemake. Animating rotation with quaternion curves. In *ACM SIGGRAPH computer graphics*, volume 19, pp. 245–254. ACM, 1985.
- Tom White. Sampling generative networks: Notes on a few effective techniques. *arXiv preprint arXiv:1609.04468*, 2016.
- Gale Young. Maximum likelihood estimation and factor analysis. *Psychometrika*, 6(1): 49–53, 1941.

A 更多遍历实验

A.1 直线欧几里得遍历




图 8: 在 LSUN 厨房场景上进行的直线欧几里得遍历，使用正常（上方）和伽马（下方）先验。




图 9: 在 LSUN 卧室场景上进行直线欧几里得遍历, 使用标准先验 (上方) 和伽马先验 (下方)。




图 10: 在 MNIST 数据集上进行直角欧几里得遍历, 使用正态先验 (上方) 和伽马先验 (下方)。




图 11: 在 SVHN 上进行直截了当的欧几里得遍历，使用标准先验（上方）和伽马先验（下方）。




图 12: 在 CIFAR10 上进行直截了当的欧几里得遍历, 使用正常 (上方) 和伽马 (下方) 先验。

A.2 球面测地线遍历




图 13: 在 LSUN 厨房场景下, 球面测地线遍历, 使用正态先验 (上方) 和伽马先验 (下方)。




图 14: 在 LSUN 卧室数据集上, 使用正态先验 (上方) 和伽马先验 (下方) 进行球面测地线遍历。




图 15: 在 MNIST 数据集上使用正态先验（上方）和伽马先验（下方）进行球面测地线遍历。




图 16: 在 SVHN 数据集上, 使用正态先验 (上方) 和伽马先验 (下方) 进行球面测地线遍历。





图 17: 在 CIFAR10 上基于球面测地线遍历, 使用正态先验 (上) 和伽马先验 (下)。

B 更多关于潜在空间维度的实验比较

normal prior




gamma prior



表 2: 在 LSUN 厨房数据集上, 使用正态 (顶部) 和伽马 (底部) 先验对不同潜在空间维度的生成器进行直接遍历。

normal prior



gamma prior



表 3: 在 LSUN 卧室数据集上, 使用正态 (顶部) 和伽马 (底部) 先验, 对不同潜在空间维度的生成器进行直接遍历。

normal prior

d=2

d=3

d=5

d=10

d=50

d=200

表 4: 在具有不同潜在空间维度的 MNIST 数据集上, 使用标准先验 (顶部) 和伽马先验 (底部) 进行生成器的直接遍历。

normal prior



gamma prior



表 5: 在 SVHN 数据集上, 使用正态 (顶部) 和伽马 (底部) 先验的生成器中, 对不同潜在空间维度进行直接遍历。




表 6: 在 CIFAR10 数据集上, 使用正常先验 (上方) 和伽马先验 (下方) 时, 生成器在不同潜在空间维度下的直接遍历。

C 实验设置

在我们的实验中，我们采用标准的 DCGAN 架构，该架构包含 5 层反卷积和卷积层，生成器和判别器分别使用步幅为 2 的 4×4 个滤波器。生成器使用 ReLU 非线性激活函数和批量规范化，而判别器从第 2 层开始使用 Leaky Relu 非线性激活函数和批量规范化。所有模型的潜在空间维度为 100，且正态分布和 Gamma 分布的尺度参数均设置为 1.0。网络使用 RMSProp 进行训练，学习率为 0.0003，批量大小为 100。

CelebA 数据集的样本已裁剪为 118×118 ，然后调整大小至 64×64 。